

## **Dataset: Covid-19, estadísticas diarias por países en el mundo**

*Jhon H. Loaiza G.*

*Pablo Jesús Sánchez Vargas*




Figura 1. Imagen de referencia del virus Covid-19, CDC

### **Descripción**

Dada la coyuntura mundial por la emergencia sanitaria, provocada por el Covid-19 y su rápido crecimiento en contagios a nivel global, hemos decidido hacer un aporte al poder descargar los datos de una de las páginas más importantes para analizar el comportamiento de la covid-19. Este dataset es creado a partir del sitio web [Worldometers](https://www.worldometers.info/coronavirus/) la práctica de Webscraping del curso de Tipología y ciclo de vida del dato, del master en Ciencia de datos de la UOC.

El dataset consta de la información de casos reportados por países a nivel mundial, fallecimientos, pruebas realizadas, casos recuperados, población, entre otras.

### **Contexto**

Dada la emergencia sanitaria actual, es una necesidad de los gobiernos nacionales y entidades de salud a nivel mundial, reportar las estadísticas del Covid-19 en sus territorios, principalmente de casos nuevos, fallecimientos, recuperados, así como también el número de pruebas o test realizados a la población. El dataset muestra la información actualizada al día (nuevos casos y fallecimientos del día) y acumulado de casos totales por país. Además, es capaz de recoger automáticamente nuevos datos cada 24 horas.

## Contenido

Para cada país, se recopila la siguiente información:

- **#:** Posición del país en el listado basado en número de casos totales
- **Country/Other:** Nombre del país
- **TotalCases:** Casos totales acumulado
- **NewCases:** Casos nuevos del día
- **TotalDeaths:** Fallecimientos totales acumulado
- **NewDeaths:** Fallecidos nuevos del día
- **TotalRecovered:** Total de recuperados
- **NewRecovered:** Recuperados nuevos del día
- **ActiveCases:** Casos activos acumulado
- **Serious,Critical:** Casos críticos (en UCI u hospitalizados)
- **TotCases/1M pop:** Total de casos por cada millón de habitantes
- **Deaths/1M pop:** Fallecimientos por cada millón de habitantes
- **TotalTests:** Cantidad total de tests realizados
- **Tests/1M pop:** Tests realizados por cada millón de habitantes
- **Population:** Población o cantidad de habitantes
- **Continent:** Continente al cual pertenece el país
- **1 Caseevery X ppl:** 1 caso cada X cantidad de Habitantes
- **1 Deathevery X ppl:** 1 fallecimiento cada X Habitantes
- **1 Testevery X ppl:** 1 test cada X Habitantes

La web de [Worldometers](#) habilito este sitio desde el inicio de la pandemia y se asume que estará activo hasta que termine la misma. [Worldometers](#) recopila y valida la información de distintas fuentes acerca del covid-19, haciéndola una fuente confiable para el seguimiento de la pandemia.

## Agradecimientos

Como se ha mencionado anteriormente, los datos han sido extraídos de la web de [Worldometers](#), dadas su validez y controles de las fuentes de información, lo hace un sitio referencia en materia de estadísticas de Covid-19, ya que trabaja directamente con fuentes de John Hopkins y del CDC en Estados Unidos. La extracción se realizó usando tecinas de Webscraping con Python y las librerías requests y lxml, y se automatizó el proceso utilizando la librería scheduler. El sitio presenta la información ordenada y de manera de adecuada que permite la extracción de la misma usando las librerías mencionadas.

## Inspiración

Al ser una información valiosa dada la situación actual a nivel global, y a pesar que puede ser consultada en la web, el poder tener los datos en archivos, con las cifras actualizadas diariamente,

permite ver tendencias de nuevos casos en los distintos países, así como el comportamiento de las medidas y controles que están haciendo los países y su efectividad en la disminución de los casos, basado en un histórico de estos datos. Este dataset podría ser interesante para muchos ámbitos, principalmente epidemiólogos, científicos de datos que quieran modelar el comportamiento del covid-19, medios de comunicación y revistas especializadas en salud. El script puede automatizarse para generar los archivos con las cifras de Covid-19.

## Licencia

Para este conjunto de datos, se escoge la licencia **Attribution 4.0 International (CC BY 4.0)**, la cual se considera idónea, dado que los datos que se extraen son de carácter público y este proyecto facilita la obtención y posible almacenamiento de esa información. La licencia cuenta con una única cláusula:

- **Atribución** — Debe darse el crédito a la persona o creador de los datos en este caso, indicando que cambios se le han realizado. Es un reconocimiento al trabajo realizado.

Esta licencia permite usar los datos, transformarlos y compartirlos, además se pueden usar para fines comerciales sin ninguna restricción.

## Código fuente y dataset

El código fuente y el dataset resultante pueden ser descargados del siguiente link: <https://github.com/JhonHarry/WebScraping>.

Una dificultad presentada al extraer los datos fue el traslape de tablas, ya que el sitio presenta valores ocultos de otras regiones (continentes) que no eran el objeto del dataset, por lo que se tuvo que buscar la manera en el xpath de no traer esos valores que al final se resolvió y permitió obtener la data deseada.

## Zenodo/DOI del dataset

El código del dataset es 10.5281/zenodo.4245341

Se puede consultar en <https://zenodo.org/record/4245341#.X6NQYVC2200>

Se usó el dataset generado para el día 3 de noviembre de las estadísticas, dado que es una información que se puede scrapear a diario.

## Recursos

- Subirats, L., Calvo, M. (2018). *Web Scraping*. Editorial UOC.
- Lawson, R. (2015). *Web Scraping with Python*. Packt Publishing Ltd. Chapter 2. Scraping the Data.